

가짜뉴스 탐지 시스템 정리 (1~2단계)

1단계. 데이터 가져오기

목적

여러 개의 CSV 파일에서 필요한 뉴스 데이터를 읽어와 하나의 데이터셋으로 통합한다.

핵심 개념

대용량 데이터를 한 번에 모두 읽으면 메모리 사용량이 급격히 증가할 수 있기 때문에, 읽을 데이터 양을 제한한다.

주요 코드 요소

```
MAX_ROWS_PER_FILE = 30000
```

- 각 파일에서 최대 30,000줄까지만 읽도록 제한
- 메모리 과부하 방지 목적

```
pd.read_csv(..., nrows=MAX_ROWS_PER_FILE)
```

- CSV 파일을 읽는 함수
- `nrows` 옵션을 사용해 필요한 양만 읽음

핵심 변수

변수	의미
<code>X</code>	뉴스 본문 데이터 (문제집 역할)
<code>y</code>	진짜/가짜 라벨 데이터 (정답지 역할)

`X`

- `content`
- `clean_message`

두 텍스트를 합쳐서 학습 데이터로 사용한다.

`y`

- 0 → 진짜 뉴스
- 1 → 가짜 뉴스

2단계. 텍스트를 숫자로 변환

목적

컴퓨터가 이해할 수 있도록 문자를 숫자 형태로 변환한다.

핵심 개념

컴퓨터는 문장을 직접 이해하지 못하기 때문에, 단어의 중요도를 계산하여 숫자로 변환해야 한다.

데이터 분할

```
train_test_split(...)
```

전체 데이터를 다음과 같이 분리한다.

구분	비율	역할
학습 데이터	80%	인공지능 학습
테스트 데이터	20%	성능 평가

이유

학습에 사용한 문제를 그대로 시험에 사용하면 실제 성능을 확인할 수 없기 때문이다.

TF-IDF 변환

```
TfidfVectorizer(max_features=30000)
```

텍스트 데이터를 숫자로 변환하는 핵심 도구이다.

TF-IDF 원리

단어 유형	처리 방식
자주 등장하는 일반 단어	낮은 점수 부여
특정 문서에서 중요한 단어	높은 점수 부여

예시:

- “그리고”, “하지만” → 중요도 낮음
- “조작”, “충격”, “폭로” → 중요도 높음 가능성

`max_features=30000`

- 가장 중요한 단어 30,000개만 사용
- 불필요한 단어 제거 효과