

1. 원본 데이터 소스

1. kaggle

fake-and-real-news-dataset

- Fake.csv (title/text/subject/date 컬럼, 23,503건)
- True.csv (title/text/subject/date 컬럼, 21,418건)

Fake and Real News Data

- Fake_Real_News_Data.csv (title/text/label 컬럼, 16,748건)

2. aihub

남시성 기사 탐지 데이터

한국어 zip 로드(Training 42개, Validation 42개 파일)

-(newsID/newsCategory/newsTitle/newsContent/sentenceCount/processLevel 컬럼, 660,085건)

2. 데이터 표준 스키마

컬럼명	타입	설명
id	int	행 고유 식별자 (1부터 순번)
title	str	기사 제목 (원문)
content	str	기사 본문 (원문, 최대 10,000자)
media	str	출처 매체명 (불명 시 `Unknown`)
date	str	발행일 (`YYYY-MM-DD`, 불명 시 `YYYY-01-01` 또는 ``)
label	int	정답 레이블 (`0` = 진짜, `1` = 가짜)
clean_message	str	학습용 정제 텍스트 (소문자, HTML·특수문자 제거)
stat_distortion	int	통계 왜곡 (0 또는 1)
causal_error	int	인과 오류 (0 또는 1)
emotional_provocation	int	감정 자극 (0 또는 1)
source_lack	int	출처 불명 (0 또는 1)
img_mismatch	int	이미지 불일치 (0 또는 1)

3. DVL 5대 패턴 분류

1. stat_distortion - 통계 왜곡

수치나 빈도를 과장·절대화하는 표현을 사용해 독자에게 사실처럼 보이게 만드는 패턴입니다.

- 탐지 키워드: 100%, 모든, 항상, 절대, never, always
- 예시: "모든 전문가가 동의한다", "항상 이래왔다"

2. causal_error - 인과 오류

무관하거나 검증되지 않은 두 사건을 원인-결과로 연결하는 패턴입니다.

- 탐지 키워드: 때문에, 원인, 증명, 결과적으로, causes, proves
- 예시: "A 때문에 B가 발생했다는 것이 증명됐다"

3. emotional_provocation - 감정 자극

독자의 분노·공포·혐오 감정을 의도적으로 유발해 비판적 사고를 차단하는 패턴입니다.

- 탐지 키워드: 충격, 경악, 분노, shocking, outrage, unbelievable
- 예시: "충격적인 진실이 밝혀졌다", "unbelievable scandal"

4. source_lack - 출처 불명

익명의 관계자나 불특정 소식통에만 의존해 검증 불가능한 주장을 사실처럼 서술하는 패턴입니다.

- 탐지 키워드: 관계자, 소식통, 익명, sources say, reportedly
- 예시: "익명의 관계자에 따르면", "sources say the president..."

5. img_mismatch - 이미지 불일치

본문 내용과 무관한 사진이나 영상을 사실인 것처럼 연결하는 패턴입니다.

- 탐지 키워드: 사진 속, 이 사진은, photo shows, pictured here
- 예시: "이 사진은 현장을 포착한 것이다", "photo shows the incident"

4. 전처리 파이프라인 상세

Stage 1 - preprocess.py (원본 통합)

처리 내용	기준
여러 CSV 파일 통합	
완전 중복 제거	title + content MD5 해시
본문 최소 길이 필터	content 20자 미만 제거
날짜 정규화	`YYYY-MM-DD` 통일
결측치 처리	컬럼별 최빈값으로 대체
clean_message 생성	HTML 제거 → 소문자 → 특수문자 제거
DVL 패턴 플래그 생성	5개 키워드 그룹 탐지

Stage 2 - refine.py (품질 정제)

처리 내용	기준
길이 하한 필터	content < 150자 제거
길이 상한 truncate	content > 10,000자 잘라냄
특수 문자 비중 필터	비표준 문자 비율 > 35% 제거
보일러플레이트 필터	저작권 문구 제거 후 50자 미만 제거
외국어 혼입 필터	중국어·일본어 비율 > 10% 제거
유사 제목 중복 제거	character trigram Jaccard $\geq$ 90% 제거
DVL 미검출 가짜뉴스 제거	5개 패턴 모두 0인 label=1 제거
클래스 균형 (1:1)	가짜뉴스 중 DVL 점수 높은 것 우선 보존

-처리 전후 비교

구분	행 수	label=0 (진짜)	label=1 (가짜)
처리 전	595,910	241,736	354,174

처리 후	365,168	182,584	182,584
------	---------	---------	---------

-컬럼명 및 결측치 요약

구분	타입	결측치 수	결측치 비율
id	int64	0	0.00%
title	object	0	0.00%
content	object	0	0.00%
media	object	0	0.00%
date	object	557,324	93.52%
label	int64	0	0.00%

DVL 패턴	감지 건수	비율
stat_distortion	108,581	18.2%
causal_error	115,322	19.4%
emotional_provocation	40,722	6.8%
source_lack	122,906	20.6%
img_mismatch	5,340	0.9%

-처리 결과 요약

조건	제거 행	잔여 행
		595,910
content < 150 제거	733	595,177
content > 10,000자 truncate	881	595,177
특수 문자 비중 > 35%	0	595,177
보일러플레이트 위주 기사	0	595,177
중국어·일본어 혼입 > 10%	4	595,173
유사 제목 (Jaccard $\geq$ 90%)	4,252	590,921
DVL 패턴 없는 가짜뉴스	168,900	422,021
클래스 1:1 균형맞추기	56,853	365,168

595,910행 → 365,168행 (38% 감소), label=0/1 각 182,584개로 균형

- 추가 전처리

	1차 전처리	2차 전처리
파이프라인	preprocess.py + refine.py (2단계)	preprocess.py 단일 통합
한국어 로딩	별도 방식으로 로딩	_load_korean_zip → 단일 seen 집합
dedup 범위	Training/Validation 각각 독립적 처리 가능성	모든 소스를 하나의 seen 집합으로 전역 통합

데이터 건수 : 595,910 → 592,893(3,017건, seen 집합으로 중복 제거)

365,168 → 343,208(21,960건, _step_undersample의 증폭 효과)

최종 출력 : data/processed/unified_news_refined.csv

-모델 학습용 데이터 셋

파일	건수	진짜	가짜
subset_01 ~ subset_10	각 30,000	15,000	15,000
subset_11	43,208	21,604	21,604
합계	343,208	171,604	171,604

5. 파일별 역할

- 전체 흐름

원본 데이터(zip/csv) → src/preprocess.py(1단계: 데이터 정제)

→ unified_news_refined.csv → src/split_dataset.py(선택적, subset 분할)

→ main.py → src/train.py(2단계: 학습 실행)

→ checkpoints/best_model.pt

-핵심 데이터 흐름 정리

preprocess.py

- |— _load_english_sources() → Fake.csv / True.csv / Fake_Real_News_Data.csv
- |— _load_korean_zip() → Training·Validation ZIP의 JSON 파일들
- |— extract_features() → clean_message + DVL 5개 컬럼 생성
- |— apply_quality_filters() → 7단계 필터 → unified_news_refined.csv

train.py

- |— FakeNewsDataset → clean_message를 그때그때 토크나이징 (Lazy)
- |— collate_fn → 배치마다 Dynamic Padding
- |— RoBERTaHybridClassifier → RoBERTa + DVL flags 결합 분류
- |— best_model.pt → val macro-F1 최고 시점 저장

- 파일별 상세 역할

파일	역할	주요 기능
src/preprocess.py	데이터 전처리	① 영어 CSV + 한국어 ZIP→JSON 로딩 및 전역 중복 제거 ② DVL 5개 패턴 키워드 추출 ③ 품질 필터 7단계 적용 → unified_news_refined.csv 저장
src/split_dataset.py	대용량 데이터 분할	refined.csv를 30,000건 단위 subset으로 분할 저장. 메모리가 부족하거나 실험할 때 subset 단위로 학습할 때 사용
src/dataset.py	PyTorch Dataset정의	① FakeNewsDataset: 텍스트+DVL 플러그+label을 Lazy Tokenization으로 제공 ② collate_fn: 배치마다 가장 긴 문장 기준 Dynamic Padding 적용
src/model.py	하이브리드 분류 모델 정의	KLUE-RoBERTa [CLS] 벡터(768차원) + DVL flags(5차원) → MLP(773→512→128→2) → 진짜/가짜 이진 분류.레이어 동결 옵션 포함
src/train.py	학습 실행 핵심스크립트	① 데이터 로딩 & train/val 분할 ② DataLoader 구성 ③ 모델·옵티마이저·스케줄러 설정 ④ 에포크별학습+평가 루프 ⑤ best F1 모델 체크포인트 저장 ⑥ 결과 txt 파일 출력
main.py	학습 진입점	전처리 파일 존재 여부 체크 후 학습 시작. python main.py 로 간단히 실행 가능
requirements.txt	의존성 목록	필요한 패키지 목록
README.md	프로젝트 설명	프로젝트 개요 문서

6. 기술 스택

- Language & Runtime

항목	내용
Python	3.10+

- AI / ML

항목	내용
----	----

PyTorch	딥러닝 프레임워크, 모델 학습·추론
HuggingFace Transformers	KLUE-RoBERTa 모델 및 토큰라이저 로드
KLUE-RoBERTa-base	한국어 사전학습 언어 모델 (klue/roberta-base)
scikit-learn	데이터 분할(train_test_split), 성능 평가(accuracy, macro-F1)

-데이터 처리

항목	내용
pandas	CSV 로드·저장, 데이터프레임 처리
numpy	배열 연산, DVL 플러그 수치화
tqdm	전처리·학습 진행률 표시
zipfile / json / csv	한국어 zip 데이터 파싱 (표준 라이브러리)
re / hashlib	텍스트 정제, 중복 제거 해시 (표준 라이브러리)

-핵심 설계 기법

항목	내용
DVL (Dynamic Verification Layer)	5개 패턴(통계왜곡·인과오류·감정자극·출처불명·이미지불일치) 키워드 기반수치화
Hybrid Architecture	RoBERTa CLS 벡터(768차원) + DVL 수치(5차원) → MLP → 이진 분류
Lazy Tokenization	학습 시점에만 토큰화하여 RAM 절약
Dynamic Padding	배치 내 최장 시퀀스 기준 패딩, 연산 효율화
Linear Warmup 스케줄러	초반 학습률 점진 증가로 학습 안정화
Gradient Clipping	그래디언트 폭주 방지 (max norm=1.0)