

대규모 언어 모델을 활용한 한국어 가짜뉴스 탐지: 한계와 가능성¹⁾

Detecting Fake News in Korean Using Large Language Models: Limitations and Possibilities

고상훈 (Sang Hun Ko)

국민대학교 비즈니스IT전문대학원²⁾

안현철 (Hyunchul Ahn)

국민대학교 비즈니스IT전문대학원³⁾

〈 국문초록 〉

가짜뉴스는 디지털 플랫폼과 소셜 미디어를 통해 빠르게 확산되며, 사회적 신뢰와 공적 담론에 부정적인 영향을 미치는 중요한 문제로 대두되고 있다. 그런 가운데 최근 대규모 언어 모델(Large Language Models)의 발전은 자연어 처리 기술의 새로운 가능성을 열었으며, 이러한 모델의 활용은 가짜뉴스 탐지와 같은 중요한 사회적 문제 해결에도 기여하고 있다. 본 연구는 가짜뉴스의 여러 유형 중 허위정보(misinformation)를 중심으로 한국어 환경에서 LLM 기반 가짜뉴스 탐지의 가능성과 한계를 분석하고자 한다. 이를 위해 서울대학교 SNU팩트체크에서 수집한 500개의 한국어 뉴스 기사를 기반으로 한 벤치마크 데이터셋을 구축하였으며, 기사 요약 방식을 적용하여 추출형 및 생성형 데이터셋을 추가로 설계하였다. 본 연구는 세 가지 연구 질문을 중심으로 진행되었다: (1) 한국어 환경에서 LLM 기반 가짜뉴스 탐지가 효과적인가, (2) 어떤 요약방식이 LLM을 활용한 가짜뉴스 탐지에 효과적인가?, (3) 탐지 성능을 향상시키기 위한 최적의 방법은 무엇인가? 분석 결과, 한국어 데이터셋에서 LLM 기반 탐지 성능은 영어 중심 연구 대비 낮은 정확도(59.8%)를 보였다. 또한, 요약 텍스트를 활용한 실험에서는 문장이 짧아질수록 탐지 성능이 감소하였으며, 생성형 요약이 추출형 요약보다 다소 우수한 성능을 보였다. 마지막으로, 가짜뉴스 탐지의 기준이 되는 7가지 이유를 반영한 개선된 프롬프트를 도입하여 탐지 정확도를 소폭(62.1%) 개선할 수 있었다. 본 연구는 한국어 환경에서의 LLM 기반 가짜뉴스 탐지 연구를 확장하며, 고도화된 프롬프트 설계와 맥락적 요인을 고려한 접근이 탐지 성능 향상에 기여할 수 있음을 입증하였다. 연구 결과는 가짜뉴스 탐지뿐 아니라 다양한 언어 및 문화적 맥락에서의 LLM 활용 가능성을 제시하며, 향후 연구 및 실무적 응용에 중요한 시사점을 제공한다.

주제어: 가짜뉴스 탐지, 허위정보, 대규모 언어 모델, 한국어 데이터셋, 요약

1) 본 논문은 2024년 국민대학교 비즈니스IT전문대학원 고상훈의 석사학위논문으로 준비 중인 “한국어 환경에서 LLM 기반 가짜뉴스 탐지의 한계와 가능성”을 기반으로 작성되었으며, 2022년 대한민국 교육부와 한국연구재단의 인문사회분야 중견연구자지원사업의 지원을 받아 수행된 연구임 (NRF-2022S1A5A2A01048638).

2) 제1저자, haesam01@kookmin.ac.kr

3) 교신저자, hcahn@kookmin.ac.kr

1. 서론

대규모 언어 모델(Large Language Models, 이하 LLM)의 등장과 발전은 자연어 처리 기술의 혁신을 상징하며, 인간 수준의 언어 이해와 생성 능력을 통해 다양한 분야에서 강력한 도구로 자리 잡았다(Bommasani et al., 2021). LLM은 방대한 데이터를 학습하여 텍스트 생성, 요약, 번역 등 복잡한 작업을 수행하며 기존 언어 모델의 한계를 극복한 진보된 성능을 보여준다(Brown et al., 2020). 그 예로 더불어 ChatGPT(OpenAI, 2023)와 LLaMA(Touvron et al., 2023)와 같은 LLM은 이미 상용화되어 다양한 산업 분야에서 유용하게 사용되고 있다. 이러한 기술적 진보를 통해 심각한 사회적 문제를 해결하기 위한 시도 역시 활발하게 이루어지고 있다.

가짜뉴스는 디지털 플랫폼과 소셜 미디어의 알고리즘적 증폭을 통해 확산 속도가 가속화되며, 사회적 신뢰를 저해하고 문화적 갈등을 심화시키는 문제로 주목받고 있다(김민정, 2019; 이민철, 윤현식, 2020). 특히 COVID-19 팬데믹 당시 개인의 건강과 관련된 허위조작정보는 전 세계적으로 큰 혼란을 초래하였다(정두흠, 박지혜, 2021). 최근에는 이러한 가짜뉴스가 고의적으로 왜곡되거나 조작된 콘텐츠로, 정치적, 상업적, 사회적 목표를 달성하기 위해 설계되는 경우가 증가하고 있다. 예를 들어, 특정 정치 집단이 여론을 조작하거나 선거 결과에 영향을 미치기 위해 가짜뉴스를 활용하며, 문화적 정체성을 왜곡하는 가짜뉴스는 소수 집단에 대한 편견과 차별을 심화시키기도 한다. 이러한 가짜뉴스는 사회적 불안을 조장하고 공적 담론의 신뢰성을 심각하게 저해하는 주요 원인으로 작용한다(USC Today, 2024).

이에 따라 최근 학계에서는 LLM을 활용한 가짜뉴스 탐지에 관한 다양한 연구와 시도가 이루어지고 있다(Hu et al., 2023). 예를 들어, LLM을 이용해 인간이 작성한 뉴스 데이터와 LLM이 생성한 데이터를 조합하여 가짜

뉴스 데이터셋을 생성하고 이를 기반으로 탐지 성능을 평가하는 연구(Jiang et al., 2024), 또는 기존 자연어처리(NLP) 기반 가짜뉴스 탐지 모델에 LLM을 결합해 성능을 향상시키고자 하는 연구 등이 있다. 그러나 대부분의 기존 연구는 영어 환경에 치중되어 있으며, 이는 몇 가지 구조적 요인에서 기인한다.

첫째, LLM의 학습 데이터는 영어 콘텐츠에 편중되어 있다. 대부분의 대규모 언어 모델은 영어권 웹사이트, 뉴스, 서적 등의 자료를 주로 학습 데이터로 활용하며, 한국어 콘텐츠는 상대적으로 제한적으로 포함되어 있다. 이러한 데이터 불균형은 비영어권 언어, 특히 한국어와 같은 언어에서 모델 성능을 평가하거나 검증하는 데 어려움을 초래한다.

둘째, 한국어를 포함한 비영어권 언어는 고유한 언어적 특성과 문법 구조를 가지고 있다. 따라서, 영어 중심으로 설계된 LLM이 한국어 텍스트를 처리하는 데 한계를 보인다.

셋째, 전술했듯이 한국어 데이터셋은 공개된 데이터셋이 제한되어 있어, 한국어 데이터셋의 구축과 관리에 많은 자원이 요구된다. 따라서, 활용 가능한 시간이나 예산이 충분하지 않은 연구자들은 상대적으로 접근성이 높은 영어 데이터셋을 활용하는 경향이 크다.

이와 같은 요인들은 기존 연구들이 한국어 환경에서 실증적으로 이루어지지 않는 배경으로 작용하며, 결과적으로 한국어 기반 가짜뉴스 탐지 연구에 중요한 공백을 형성하고 있다. 이는 한국어 환경에서 가짜뉴스 탐지 기술의 실효성에 대한 검증이 부족함을 의미하며, 이러한 공백은 다음과 같은 문제를 초래한다. 우선 한국어 기반 플랫폼에서 발생하는 허위정보를 효과적으로 탐지하지 못함으로써 정보 확산을 제어하는 데 한계가 있다. 더불어 비영어권 환경에서 LLM의 성능 한계를 정확히 이해하지 못한 상태에서는 다국어 언어 모델의 효과적인 개선 전략을 도출하기 어렵다.

따라서 본 연구는 이러한 공백을 메우기 위해, 한국어 환경에서 LLM 기반 가짜뉴스 탐지 모델의 성능을 실증적으로 평가하고 탐지 성능을 향상시키기 위한 방안을 제안하고자 한다. 이를 위해 설정한 본 연구의 핵심 연구 질문은 다음과 같다.

- RQ1: LLM 기반 가짜뉴스 탐지 기법이 한국어 환경에서도 효과적인가?
- RQ2: 어떤 요약방식이 LLM을 활용한 가짜뉴스 탐지에 효과적인가?
- RQ3: LLM의 가짜뉴스 탐지 성능을 어떻게 향상시킬 것인가?

연구 결과가 실질적인 시사점을 제시하도록 하기 위해, 본 연구는 한국어 환경에서 LLM을 활용한 가짜뉴스 탐지를 체계적으로 분석하였다. 연구의 목적은 LLM이 어떤 방식으로 가짜뉴스를 탐지하는지 규명하고, LLM 단독으로 가짜뉴스 탐지 시 발생하는 한계를 파악하며, 이를 극복하기 위한 대안적 방법을 모색하는 데 있다. 이를 위해 본 연구에서는 SNU 팩트체크에서 수집된 500개의 한국어 뉴스 기사 전문으로 이루어진 데이터셋을 기반으로 벤치마크 데이터셋($D_{full-text}$)을 구성하였다. 이 데이터셋을 바탕으로 두 가지의 요약 프롬프트를 사용하여 생성형과 추출형의 서로 다른 유형의 가짜뉴스 데이터셋(D_{ext} , D_{gen})을 구축하였다.

먼저 LLM 기반 가짜뉴스 탐지 기법이 한국어 환경에서도 효과적인지 알아보기 위해 기사 전문으로 이루어진 가짜뉴스 데이터셋에 제로샷 프롬프트 기법을 활용하여 허위정보 탐지 프롬프트를 활용한 실험을 진행하였다. 이후, 생성형과 추출형 데이터셋을 바탕으로 LLM이 어떤 요약 방식에서 가짜뉴스 탐지에 더 효과적인지 분석하였다. 마지막으로, LLM의 가짜뉴스 탐지 성능을 향상시키기 위해, 보다 정확하게 허위정보를 탐지할 수 있도록 LLM의 허위정보 탐지 프롬프트를 개선하는 방안을 제안하였다.

이후 논문의 구성은 다음과 같다. 2장에서는 가짜뉴스 및 LLM의 개념을 포함한 이론적 배경을 제시한다. 3장에서는 연구에서 활용된 데이터셋 및 프롬프트 설계 방식을 상세히 설명한다. 4장에서는 실험 결과를 바탕으로 한국어 환경에서 LLM 기반 가짜뉴스 탐지의 성능을 평가하고, 탐지에 적합한 요약 방식을 고찰하며, 성능을 개선하기 위한 프롬프트 개선 방안을 논의한다. 마지막으로, 5장에서는 연구 결과를 종합적으로 정리하고, 본 연구의 시사점 및 한계와 함께 향후 연구 방향을 제안한다.

2. 이론적 배경

2.1. 가짜뉴스

가짜뉴스(fake news)는 의도적으로 거짓이거나 오해를 불러일으킬 수 있는 정보를 뉴스 형식으로 제시하며, 설계 단계에서부터 대중을 오도하거나 혼란시키기 위해 체계적으로 설계된 정보를 의미한다(Gelfert, 2018). 이는 뉴스 형식을 모방하여 신뢰성을 갖춘 것처럼 보이게 하면서도, 고의적으로 잘못된 정보를 포함하거나 선택적으로 진실을 왜곡하여 대중의 인지적 판단에 영향을 미친다.

가짜뉴스는 위기 상황에서 더욱 활발히 발생하는 경향이 있다. 특히 디지털 기술과 소셜 미디어의 발달은 가짜뉴스의 확산 속도와 범위를 비약적으로 확대시켰다. 예를 들어, COVID-19 팬데믹 초기에는 백신 부작용과 관련된 잘못된 정보가 소셜 미디어에서 빠르게 확산되었으며, 이는 예방 접종에 대한 거부감을 증가시키는 결과를 초래하였다. 이러한 가짜뉴스는 개인뿐만 아니라 공중보건 정책에도 부정적인 영향을 미치며, 사회적 혼란을 가중시켰다. 이처럼 가짜뉴스는 단순한 오류를 넘어, 의도적인 조작과 감정적 호소를 통해 사회적 영향력을 극대화하려는 특징을 지닌다(정두흠, 박지혜, 2021).

가짜뉴스의 조작 방식은 크게 세 가지로 나눌 수 있다 (Gifu, 2023). 첫째, ‘정보 왜곡’은 기존 사실을 일부 과장하거나 축소하여 전달함으로써 본질적인 의미를 변형한다. 둘째, ‘사실과 허위의 혼합’은 신뢰를 얻기 위해 진실된 정보와 가짜뉴스를 결합하는 방식으로 작동한다. 셋째, ‘감정적 접근’은 공포나 분노와 같은 감정을 자극하여 정보의 확산 속도를 높인다. 예를 들어, 감염병과 관련된 공포심을 자극하는 가짜뉴스는 사람들의 합리적 판단을 방해하며, 잘못된 행동으로 이어질 가능성을 높인다.

특히, 소셜미디어 환경에서 가짜뉴스는 확증 편향 (confirmation bias)과 쾌락적 사고방식(hedonistic mindset)의 영향을 크게 받는다. 확증 편향이란 사용자가 자신의 기존 신념과 일치하는 정보에만 주의를 기울이고 이를 더 쉽게 믿는 경향을 말한다(Kahneman, 2011). 소셜미디어는 알고리즘을 통해 사용자의 선호에 맞춘 정보를 제공하기 때문에, 사용자가 신념에 부합하는 뉴스에 반복적으로 노출되어 이러한 편향이 더욱 심화된다. 또한, 사용자가 정보 소비를 비판적으로 하기보다는 즐거움과 감정적 만족을 추구하는 쾌락적 사고방식에서 가짜뉴스를 수용하는 경향이 강화된다(Moravec et al., 2018). 예를 들어, 감정적으로 강한 호소를 담은 헤드라인은 사용자의 관심을 끌고 공유를 유도하지만, 이 과정에서 정보의 진실성은 간과되기 쉽다. 이러한 맥락에서 가짜뉴스는 소셜미디어의 속성과 사용자의 인지적 특성에 의해 더욱 빠르고 광범위하게 확산된다.

이러한 가짜뉴스의 조작 방식을 바탕으로 가짜뉴스는 크게 두 가지 유형으로 구분할 수 있다. 첫째는 조작정보(disinformation)이다. 조작정보는 특정한 목적을 위해 고의적으로 잘못된 정보를 조작하고 유포하여 대중을 오도하거나 혼란을 조장하는 행위를 뜻한다. 이러한 정보는 사실처럼 보이도록 구성되며, 사회적 혼란을 일으키거나 특정 개인, 단체, 혹은 정치적 이해관계를 대변하는 데 사용된다(Li et al., 2023). 둘째는 허위정보(misinformation)

로, 허위정보는 정보 제공자가 허위임을 알지 못하는 비의도성과 정보 제공자는 해당 정보를 사실로 믿고 전달하는 주관적 신뢰와 같은 특성으로 이루어져 있다. 미디어 매체에서 확인되지 않은 뉴스를 사실로 믿고 전파하거나 COVID-19사태의 경우와 같이 의학적 오해를 불러일으키는 잘못된 정보를 전파하는 것을 그 예시로 들 수 있다(Wu et al., 2019).

이처럼 가짜뉴스는 사회적 신뢰를 약화시키고 갈등을 심화시킨다(Ognyanova et al., 2020). 정치적 가짜뉴스는 특정 정당이나 정치인을 비방하거나 경쟁 세력에 대한 불신을 조장하는 방식으로 사용되며, 이는 선거와 같은 중요한 사회적 결정에 부정적 영향을 미칠 수 있다(Rossini et al., 2023). 이와 동시에 가짜뉴스를 탐지하고 대응하는 과정에서 막대한 자원과 노력이 요구되며, 이는 사회적 비용을 증가시키는 또 다른 문제를 야기한다. 따라서 가짜뉴스의 확산을 막기 위해 현재까지 다양한 연구들이 이루어지고 있다.

기존의 가짜뉴스 탐지 방법은 크게 ‘뉴스 콘텐츠 분석’과 ‘배경정보 활용’으로 나뉜다(Bondielli & Marcelloni, 2019). ‘콘텐츠 기반 접근법’으로는 Buntain and Golbeck(2017)이 트위터 데이터에서 문장부호와 감탄부호 사용 빈도를 분석해 가짜뉴스를 탐지한 연구, Pan et al.(2018)이 지식 그래프와 임베딩 모델을 사용한 사례가 있다. Sheikhi(2021)는 WOA와 xgbTree를 결합한 하이브리드 모델을, Wynne and Wint(2019)는 TF-IDF와 문자 N-gram 기반 탐지 방식을 제안했다. 하지만 콘텐츠만으로는 정교하게 설계된 가짜뉴스를 탐지하기 어려운 한계가 있다.

이에 따라 ‘배경정보 활용 방식’이 주목받게 되었다. Shim et al.(2021)은 Google 검색결과를 벡터화한 Link2vec을 활용했으며, Raza & Ding(2022)은 콘텐츠와 소셜 배경정보를 결합해 가짜뉴스를 탐지했다. Kim and Dennis(2018)는 소셜 미디어에서 가짜뉴스 탐지와 사용자 행동에 미치는 영향을 분석하기 위해 ‘출처 우선 강조 방식’과 ‘출

처 평점 시스템'을 실험적으로 검증하였다. 이 연구는 간단한 인터페이스 변경으로 사용자가 뉴스 콘텐츠를 더 회의적으로 평가하게 만들 수 있음을 보여주며, 특히 낮은 출처 평점이 신뢰성 감소에 중요한 역할을 한다는 점을 강조하였다. 국내 연구로는 박성수와 이견창(2019)이 소셜 네트워크 데이터를 Deepwalk으로 분석해 로지스틱 회귀를 적용한 사례가 있다.

이러한 흐름 속에서 가짜뉴스 탐지 연구는 최근 LLM의 등장으로 새로운 전환점을 맞이하고 있다. LLM은 방대한 데이터 학습 능력과 언어 이해 능력을 기반으로, 가짜뉴스 생성 및 탐지에 있어 강력한 도구로 주목받고 있다. LLM을 활용한 연구는 기존 콘텐츠 및 배경정보 중심의 접근법을 넘어 더욱 정교한 분석과 탐지를 가능하게 한다.

예를 들어, Xie et al.(2024)은 ChatGPT Turbo API 기반의 두 가지 LLM 에이전트(QGA, KFA)를 활용한 OKI (Open-domain Knowledge Integrated) 프레임워크를 개발하였다. 이 프레임워크는 단순 텍스트 분석을 넘어 외부 지식(위키백과 등)을 검색하고 해당 뉴스가 실제 세계와 일치하는지를 비교하여 가짜뉴스 여부를 판단한다. 또한, Zhang et al.(2023)은 가짜뉴스 생성 기법을 분석하고 이를 반대로 탐지에 적용하는 연구를 진행하였다. 이처럼 LLM을 활용한 탐지 기술은 가짜뉴스의 확산을 억제하고 정보 신뢰성을 높이는 데 중요한 역할을 한다. LLM 기반 연구는 점차 정교해지는 가짜뉴스 대응에서 필수적인 도구로 자리 잡고 있으며, 향후 관련 연구가 더욱 확대될 것으로 기대된다.

따라서, 가짜뉴스의 확산을 방지하기 위해서는 가짜뉴스의 메커니즘과 그 영향을 정확히 이해하고, 효과적인 대응 방안을 개발하는 것이 중요하다. 본 연구는 이러한 문제를 해결하기 위해, LLM을 활용한 가짜뉴스 탐지, 특히 '허위정보(misinformation) 탐지'에 초점을 맞추어 탐지 방법의 견고성을 평가하는 것을 목표로 한다.

2.2. 대규모 언어 모델(Large Language Model)

대규모 언어 모델(LLM)은 자연어 처리 기술의 중요한 진보를 이룬 모델로, 대규모 텍스트 데이터를 기반으로 학습되어 다양한 언어 기반 작업에서 뛰어난 성능을 보인다(유기동, 2024). 대표적인 예로는 OpenAI의 GPT 시리즈와 Google의 BERT 모델(Devlin, 2018)이 있다. 이러한 모델은 텍스트 생성, 번역, 요약, 감정 분석 등 다양한 작업을 수행하며, 인간과 유사한 언어 이해 및 생성 능력을 보여준다(박예은, 안현철, 2023).

LLM의 주요 특징은 방대한 데이터셋을 활용한 '사전 학습'과 특정 작업에 대한 '미세 조정'으로 구성된 학습 과정에 있다. 초기 학습 단계에서 광범위한 언어적 패턴을 이해한 후, 특정 작업에 맞춰 세부 조정을 통해 성능을 최적화한다. 또한, 제로샷(zero-shot) 및 퓨샷(few-shot) 학습 능력을 갖추고 있어 새로운 작업에 대해 추가 학습 없이도 기존 지식을 활용해 효과적으로 대응할 수 있다(Brown et al., 2020).

기존의 가짜뉴스 탐지 기법은 일반적으로 텍스트 데이터를 기반으로 특정 특징을 추출하여 탐지 모델에 입력하는 방식으로 작동한다. 예를 들어, 단어 빈도 분석이나 감정 분석과 같은 기술이 사용되지만, 이러한 방법은 특정 데이터셋에 최적화되는 경향이 있어 도메인 확장성이 낮으며, 라벨링된 데이터가 부족할 경우 성능이 제한되는 단점이 있다(Abdulrahman et al., 2020).

LLM은 이러한 기존 기법의 한계를 보완하며, 특히 가짜뉴스 탐지에서 강점을 보인다. LLM은 문맥과 관계를 깊이 이해하는 능력을 통해 복잡한 텍스트 간의 상호작용을 분석할 수 있다. 또한, 특정 도메인에 종속되지 않고 다양한 주제에서 활용 가능하며, 텍스트의 논리적 흐름과 감정적 맥락을 고려할 수 있는 장점을 가진다(Quelle & Bovet, 2024).

LLM의 이러한 특성은 가짜뉴스 탐지 분야에서 새로

운 가능성을 열며, 더 많은 데이터와 개선된 모델 설계를 통해 지속적으로 발전할 가능성이 크다. 특히, 도메인 간 독립성과 문맥 이해 능력을 활용하면 복잡한 가짜뉴스 탐지 정확도를 더욱 향상시킬 수 있다.

대규모 온라인 텍스트 데이터로 학습된 ChatGPT는 방대한 정보를 담고 있는 언어 모델로, 인간 피드백 기반 강화 학습(Reinforcement Learning with Human Feedback, RLHF)이라는 독창적인 학습 기법을 활용한다(Ouyang et al., 2022). 이 학습 과정은 모델의 출력에 대한 인간 피드백을 체계적으로 반영하여 신뢰성과 품질 높은 결과를 생성하도록 설계되었다. 이러한 접근은 단순히 데이터 학습을 넘어 자연스럽고 실질적인 응답을 생성하는 데 크게 기여한다.

특히, 최신 모델인 GPT-4o는 자연어 생성 및 이해 능력에서 뛰어난 성능을 보이며, 다양한 언어 작업에 적합한 모델로 평가받고 있다. 본 연구는 이러한 ChatGPT의 특성을 활용하여 고품질의 가짜뉴스를 탐지하고, 이를 기반으로 가짜뉴스 탐지 기법의 효과를 분석하는 것을 목표로 한다.

3. 데이터셋 및 프롬프트

이번 장에서는 본 연구에서 활용된 데이터셋에 대해 소개한다. 먼저, 본 연구의 기초가 되는 데이터는 한국어로 작성된 뉴스 기사 전문으로 이루어진 가짜뉴스 데이터셋($D_{full-text}$)이다. 이 데이터셋을 기반으로 제로샷 프롬프트 기법을 활용하여, 추출형 가짜뉴스 데이터셋(D_{ext})과 생성형 가짜뉴스 데이터셋(D_{gen})이라는 두 가지 유형의 요약 가짜뉴스 데이터셋을 추가로 구축하였다. 이러한 한국어 데이터셋은 한국어 기반 가짜뉴스 탐지 연구를 확장하는 데 기여하고자 하는 목적을 가지고 있다(Shu et al., 2020). 또한, 프롬프트 설계는 LLM(GPT-4o)

의 다양한 능력을 검증하기 위해 맞춤화되었다.

3.1. 기사 전문 데이터셋($D_{full-text}$)

가짜뉴스 탐지 분야에서 가짜뉴스와 진짜뉴스로 이루어진 데이터셋($D_{full-text}$)은 주요 벤치마크 데이터셋 중 하나로 자리잡고 있다. 본 연구에서 활용된 데이터셋은 SNU FactCheck에서 검증된 총 500개의 뉴스 기사로 이루어져 있으며, 250개의 사실로 확인된 실제 뉴스 기사와 250개의 허위정보로 분류된 가짜뉴스 기사를 포함하고 있다. SNU FactCheck는 서울대학교 언론정보연구소가 운영하는 정보서비스로, 언론사들이 검증한 공적 관심을 국민들에게 알리기 위해 설계되었다. 이 서비스는 정치, 경제, 과학, IT, 사회, 문화 등 다양한 분야에서 정확한 사실 검증이 필요한 공적 사안을 대상으로 하며, 언론사들의 검증 과정을 통해 사실 여부를 결정한다. 수집된 기사 전문은 정치, 경제, 사회 등 다양한 주제를 포괄하며, 이를 통해 허위정보 탐지 모델의 범용성과 정확성을 동시에 평가하기 위해 데이터셋이 구성되었다.

3.2. 요약형 데이터셋(D_{ext} , D_{gen})

기사 전문 데이터셋을 바탕으로 OpenAI사의 ChatGPT (GPT-4o) API를 활용하여 두 가지 유형의 추가 데이터셋을 구축하였다. 각 데이터셋은 허위정보 탐지 모델의 문맥적 이해와 정보 재구성 능력을 평가하고, 가짜뉴스 탐지에서 추출형과 생성형 중 어떤 요약 방식이 더 효과적인지 비교하기 위해 설계되었다.

추가적으로, 요약된 문장의 수에 따라 탐지 성능의 변화가 존재하는지를 확인하기 위해 각 유형별로 [1, 3, 5]개의 문장으로 요약을 진행하였다. 이를 통해 요약 방식과 요약 수준에 따른 탐지 모델의 성능 차이를 분석하고자 하였다.

3.2.1. 추출형 요약 데이터셋

추출형 요약 데이터셋은 ChatGPT를 활용하여 뉴스 기사 원문에서 핵심적인 문장을 추출하도록 명령하여 구축하였다. 추출형 요약에 사용된 프롬프트는 <그림 1>에 제시되어 있다. 원본 기사 전문 데이터셋에서 각각 [1, 3, 5]개의 핵심 문장을 원문 그대로 추출하도록 설정하였다. 이 방식은 원문의 정보를 그대로 유지하면서도 핵심 문장을 기반으로 LLM의 주요 문장 식별 능력을 검증하기 위해 설계되었다. 추출형 요약은 원문의 내용을 변형하지 않고 정보의 핵심 요소를 보존함으로써, 탐지 모델이 문서 내 주요 문장을 얼마나 정확히 식별할 수 있는지를 평가하는 데 초점을 맞추었다.

추출형 요약 프롬프트:

당신은 뉴스 기사를 분석하는 유용한 도우미입니다. 다음 [뉴스 기사]에서 가장 중요한 문장들을 추출해주세요. 각 문장들의 내용을 그대로 유지하면서 핵심적인 내용을 포함한 [1, 3, 5]개의 문장을 한 문단으로 제공해주세요.

<그림 1> 추출형 요약 프롬프트

3.2.2. 생성형 요약 데이터셋

생성형 요약 데이터셋은 ChatGPT를 활용하여 뉴스 기사 원문에서 핵심적인 문장을 선택하고 이를 재구성하여 요약을 생성하도록 명령하여 구축하였다. 생성형 요약에 사용된 프롬프트는 <그림 2>에 제시되어 있다. 생성형 요약에서는 원본 기사 전문 데이터셋의 핵심 내용을 포함한 [1, 3, 5]개의 새로운 문장을 생성하여 요약하도록 설정하였다. 이 데이터셋은 LLM의 정보 재구성 능력과 창의적 요약 능력을 평가하고, 단순 문장 추출 방식의 요약과 비교하여 생성된 요약이 원문의 주요 내용을 재구성하는 데 어떤 차이를 보이는지 분석하기 위해 설계되었다.

생성형 요약 프롬프트:

당신은 뉴스 기사를 분석하는 유용한 도우미입니다. 다음 [뉴스 기사]에서 가장 중요한 내용들을 요약해주세요. 원문을 그대로 복사하지 말고 핵심적인 내용을 바탕으로 새롭게 [1, 3, 5]개의 문장으로 요약해주세요.

<그림 2> 생성형 요약 프롬프트

4. 실험 및 결과

본 연구에서는 OpenAI의 GPT-4o모델의 API를 사용하여 실험을 수행하였으며, Python 3.13 환경에서 진행되었다. API 응답의 재현성을 위해 모든 프롬프트는 동일한 설정 하에 실행되었다.

4.1. 한국어 환경의 LLM기반 가짜뉴스 탐지 성능 분석 및 한계 (RQ1)

앞서 언급한 바와 같이, LLM을 활용한 가짜뉴스 탐지에 관한 다양한 연구가 진행되고 있다. 그러나 대부분의 연구는 영어를 기반으로 진행되었으며, 다국적 언어 환경에서는 여전히 연구가 부족한 실정이다. 본 연구는 이러한 흐름을 바탕으로 LLM이 한국어 뉴스 기사에서도 가짜뉴스, 특히 허위정보를 탐지할 수 있는지를 검증하고자 하였다. 이를 위해 GPT-4o API를 활용하여 <그림 3>에 제시된 허위정보 탐지 프롬프트를 설계하였으며, 기사 전체 내용을 기반으로 허위정보 여부를 탐지하는 프롬프트를 적용하였다.

허위정보 탐지 프롬프트:

허위정보 탐지기로서의 역할을 수행하며 다음 뉴스 기사를 분석하여 허위 정보가 포함되어 있는지 판단해주세요. 주어진 질문에 대해 '예' 또는 '아니오'로 응답해주세요.

<그림 3> 허위정보 탐지 프롬프트

프롬프트는 LLM의 허위정보 탐지 성능을 평가하고 비교 분석이 용이하도록 제로샷 프롬프트 기법을 활용하여 이진 분류 문제로 정의하였다. 우선, 한국어 환경에서 ChatGPT의 허위정보 탐지 성능을 확인하기 위해 3장에서 소개한 기사 전문 데이터셋($D_{full-text}$)을 대상으로 실험을 진행한 결과, 기사 전문 데이터셋은 59.8%의 낮은 예측 정확도를 보였다.

본 실험과 유사하게 제로샷 프롬프트 조건 하에서 영어 기반 데이터셋을 대상으로 수행된 기존 가짜뉴스 탐지 연구에서는 약 70%(Huang et al., 2024)의 정확도를 기록한 바 있다. 이를 바탕으로 볼 때, 본 연구에서 확인된 한국어 데이터셋 대상 가짜뉴스 탐지 정확도는 상대적으로 낮은 수치임을 확인할 수 있었다.

이와 같은 낮은 정확도는 한국어 데이터셋의 특수성에 기인한 것으로 보인다. 대부분의 LLM이 영어 중심으로 훈련된 탓에, 제로샷 환경에서 가짜뉴스의 사실 여부를 판단하는 과업에 대해 한국어 텍스트에서 상대적으로 낮은 성능을 보인 것으로 추정된다.


또한, 허위정보의 복잡성도 원인 중 하나로 예상된다. 허위정보는 단순히 명시적 단서나 문법적 오류를 넘어 맥락적 왜곡을 포함하는 경우가 많다. 이를 탐지하기 위해서는 고도화된 추론 능력이 필요하지만, 본 실험에서 사용된 LLM(GPT-4o)은 OpenAI의 o1이나 o3처럼 추론 기능이 강화된 LLM이 아니었기 때문에 기사 전문의 맥락을 충분히 해석하지 못해 낮은 정확도를 산출했을 가능성이 있다.

4.2. 요약 방식에 따른 LLM의 가짜뉴스 탐지 성능 비교 (RQ2)

4.1의 실험 결과는 기사 전문을 활용했음에도 허위정보 탐지에서 기대 이상의 성능을 기록하지 못했음을 보여준다. 이러한 한계를 극복하고자, 기사 전문 대신 요약된 텍스트를 기반으로 한 접근법이 탐지 성능의 향상에

기여할 수 있을지를 탐구하였다. 이에 따라 4.2에서는 기사 전문 대신 요약된 텍스트를 제공함으로써 LLM의 탐지 성능을 개선할 가능성을 분석하고자 하였다. 특히, 기사 전문과 비교했을 때 요약 텍스트가 모델의 정보 처리 효율성을 높이고, 가짜뉴스 탐지의 핵심 단서를 LLM이 보다 효과적으로 활용할 수 있을지를 실험을 통해 검토하였다(Kazemi et al., 2021).

이를 위해 두 가지 유형의 요약 접근법을 비교하였다. 첫째는 원문에서 주요 문장을 원본 그대로 추출한 추출형 요약 방식, 둘째는 ChatGPT를 활용하여 원문을 재구성하고 새롭게 생성한 생성형 요약 방식이다. 각 요약 데이터셋은 [1, 3, 5]개의 문장으로 구성된 세 가지 요약 수준으로 나뉘었으며, 탐지에 활용된 프롬프트는 4.1에서 사용된 동일한 프롬프트(<그림 3>)를 활용하였다.



〈그림 4〉 요약 방식 비교 실험 설계

〈표 1〉 요약 방식에 따른 허위정보 예측 정확도 비교

요약 문장 수	적용된 요약 방식	
	추출형 요약	생성형 요약
1문장	50.6%	53.6%
3문장	52.4%	54.4%
5문장	53.2%	57.6%

<표 1>에서 확인할 수 있듯이, 실험 결과 추출형 요약의 경우 1문장 요약은 50.6%, 3문장 요약은 52.4%, 5문장 요약은 53.2%의 정확도를 보였다. 반면, 생성형 요약의 경우 1문장 요약은 53.6%, 3문장 요약은 54.4%, 5문장 요약은 57.6%의 정확도를 기록하였다.

이 실험 결과는 몇 가지 흥미로운 사실을 도출할 수 있게 한다. 첫째, 두 가지 요약 방식 모두 요약의 길이가 짧을수록 가짜뉴스 탐지 성능이 감소하는 패턴이 확인되었다. 둘째, 추출형 요약보다 생성형 요약이 전반적으로 높은 정확도를 기록하였다. 이는 단순히 원문에서 문장을 그대로 추출하는 것보다 ChatGPT의 정보 재구성 능력과 창의적 요약 능력을 활용하는 것이 가짜뉴스의 맥락을 효과적으로 담아낼 수 있음을 시사한다.

그럼에도 불구하고, 4.2의 실험에는 한계점이 존재한다. 가장 큰 한계는 두 가지 요약 방식 모두 원본 기사 전문 데이터셋(59.8%)의 정확도를 초과하지 못한 점이다. 기사 전문이 가장 높은 탐지 성능을 기록한 것은 가짜뉴스 탐지에서 콘텐츠 품질의 중요성을 강조한다.

실제로, LLM은 가짜뉴스 탐지 시 콘텐츠 품질에 따라 판단하는 경향이 있다는 연구들이 이를 뒷받침한다. 예를 들어, 가짜뉴스는 실제 뉴스에 비해 단순한 언어와 구조를 사용하는 경향이 있고(Home & Adali, 2017), 문법적 오류와 주관적 표현이 더 빈번하다는 연구 결과가 있다(Pérez-Rosas et al., 2018). 또한, Zhou et al.(2020)은 LLM 기반 가짜뉴스 탐지 모델이 텍스트의 일관성과 논리적 구조에 민감하게 반응한다는 점을 발견하였다. 이는 잘 구성된 기사가 내용의 진실성과 무관하게 더 신뢰받을 가능성을 시사한다.

이러한 연구들은 LLM이 콘텐츠 품질에 영향을 받아 가짜뉴스 탐지 과정에서 오류를 범할 수 있다는 주장을 지지한다. 따라서, LLM을 활용한 가짜뉴스 탐지 시스템 개발 시 이러한 편향을 인식하고 이를 보완할 방안을 마련하는 것이 필요하다는 점을 본 연구는 강조하고 있다.

4.3. 이유 기반 프롬프트를 통한 가짜뉴스 탐지 성능 향상 (RQ3)

이러한 사고의 흐름 속에서 마지막 실험을 진행하였

다. LLM이 콘텐츠의 품질적 측면에 크게 영향을 받는다면, 프롬프트를 개선하여 가짜뉴스 판단 기준을 명확히 제시하는 것이 중요하다고 판단하였다. 이에 따라, Huang et al.(2024)의 연구를 참고하여 프롬프트 성능을 개선하고자 하였다.


해당 연구에서는 ChatGPT가 가짜뉴스를 판별하는 데 기여하는 요소들을 조사하여 아홉 가지 이유를 도출하였다. 연구자들은 먼저 9개의 공개 데이터셋에서 가짜뉴스를 선택한 후, ChatGPT에게 해당 뉴스가 허위인 이유를 설명하도록 요청하였다. 이후, ChatGPT가 제시한 설명을 수작업으로 요약하여 간단한 요인으로 정리하고, 이를 다시 ChatGPT에게 제안하는 과정을 반복하였다. 이를 통해 ChatGPT가 제시한 가짜뉴스 판단 기준 9가지를 최종적으로 식별하였다.

그 중에서 본 연구에 사용된 데이터셋에 적용할 수 없는 ‘조작된 이미지 및 영상’과 ‘기타’ 두 이유를 제외한 ‘감정적 편견 또는 오도 의도’, ‘증거 또는 신뢰할 수 있는 출처의 부족’, ‘상충되는 사실’, ‘비공식적인 진술 및 표현 또는 모호한 언어’, ‘근거 자료가 불충분한 경우’, ‘문맥이 부족하거나 문맥에서 벗어남’, ‘오해 또는 잘못된 인용’, ‘지나친 단순화 또는 과장’ 등 총 일곱 가지 이유를 기존 허위정보 탐지 프롬프트에 추가하여 프롬프트를 개선하였다.


이유 기반 허위정보 탐지 프롬프트

허위 정보 탐지기로서의 역할을 수행하며 다음 뉴스 기사를 분석해주세요. 허위 정보가 포함된 뉴스 기사의 특징은 ‘감정적 편견 또는 오도 의도’, ‘증거 또는 신뢰할 수 있는 출처의 부족’, ‘상충되는 사실’, ‘비공식적인 진술, 표현 또는 모호한 언어’, ‘근거 자료가 불충분한 경우’, ‘문맥이 부족하거나 문맥에서 벗어남’, ‘오해 또는 잘못된 인용’, ‘지나치게 단순화 또는 과장’ 등이 있습니다. 앞서 언급한 요소들을 고려하여 다음 뉴스 기사에 허위 정보가 포함되어 있는지 알려주세요. 허위 정보가 포함되어있는지의 여부에 대해 ‘예’ 또는 ‘아니오’로 응답해주세요.

〈그림 5〉 이유 기반 허위정보 탐지 프롬프트



〈그림 6〉 탐지 프롬프트 비교 실험 설계



〈그림 7〉 기존 프롬프트와 개선된 프롬프트 간 정확도 비교

개선된 프롬프트는 <그림 5>와 같이 구성되었으며, 프롬프트의 성능을 비교하기 위해 가장 높은 정확도를 보였던 기사 전문 데이터셋($D_{full-text}$)을 활용하여 성능 개선 정도를 직관적으로 비교하고자 <그림 6>과 같은 방식으로 실험을 진행하였다. 실험 결과, <그림 7>에서 확인할 수 있듯이, 개선된 프롬프트의 정확도는 62.1%로 기존 프롬프트의 59.8%에 비해 약 2.3%의 성능 개선이 이루어졌다. 이상의 정확도 차이가 통계적으로 유의한 지 확인하기 위해, 본 연구에서는 이분류 예측모형의 성능 비교 분석에 자주 사용되는 비모수 검정 기법 중 하나인 McNemar 검정을 실시하였다. 그 결과, 카이제곱 검정 통계량 1.124에 근사 유의확률(p-value)이 0.289로 나타나 95% 신뢰수준 하에서 통계적으로 유의한 차이는 확인되지 않았다.

Huang et al.(2024)의 연구에서는 유사한 환경에서 이 유 기반 프롬프트를 활용하여 FakeNewsNet 데이터셋에

서 가짜뉴스 탐지 정확도를 3.6% 개선한 바 있다. 비록 본 연구의 성능 향상이 해당 연구의 3.6%에 미치지 못했으며, 통계적으로도 유의하지 않은 것으로 확인되었지만, 가짜뉴스 판단 기준에 대한 명확한 이유를 제시하는 방식의 프롬프트 개선이 LLM 활용의 유효한 접근법이 될 수 있다는 가능성을 제시하였다는 점에서 의의를 찾을 수 있다.

물론, 본 실험에는 몇 가지 한계점이 존재한다. 첫째, 성능 개선폭이 제한적이라는 점에서 아쉬움이 남는다. 이는 LLM을 활용한 가짜뉴스 탐지 성능의 실질적 향상을 위해 보다 정교한 접근법과 추가적인 연구가 필요함을 시사한다(Papageorgiou et al., 2024).

둘째, 실험에 사용된 데이터셋의 특성 역시 한계 요인으로 작용하였다. 본 연구에서 사용된 한국어 뉴스 데이터셋은 전문 기자들이 작성한 높은 품질의 기사들로 구성되어 있어, LLM이 판단하기 상대적으로 쉬운 가십성 가짜뉴스나 단순한 구조를 가진 콘텐츠가 포함되지 않았다. 이러한 데이터셋 특성은 본 실험 결과의 일반화를 어렵게 하는 요인으로 작용할 가능성이 있다.

그럼에도 불구하고, 본 연구는 한국어 환경에서 LLM의 가짜뉴스 탐지 성능 개선 가능성을 실증적으로 입증했다는 점에서 중요한 의의를 갖는다. 특히, ChatGPT에게 명확한 판단의 이유를 제시함으로써 분류 성능이 2.3% 향상된 점은 주목할 만한 결과다. 이는 LLM 기반 가짜뉴스 탐지 시스템 개발 과정에서 구체적인 기준 설정과 맥락적 정보 제공이 성능 향상에 기여할 수 있음을 보여준다.

앞으로의 연구에서는 데이터셋의 다양성과 실험 방법론의 고도화를 통해 성능 개선 가능성을 폭넓게 탐구할 필요가 있다. 본 연구는 LLM의 한국어 가짜뉴스 탐지 성능에 대한 이해를 심화하는 데 기여했으며, 해당 분야의 후속 연구에 중요한 기초를 제공했다는 점에서 학술적 의의가 있다.

5. 결론 및 제언

5.1. 학술적 기여

본 연구는 한국어 환경에서 대규모 언어 모델(LLM)을 활용한 가짜뉴스 탐지의 가능성과 한계를 체계적으로 분석하며, LLM 기반 탐지 시스템의 성능 개선 방안을 제안하였다. 특히, 기존 영어 중심 연구와 비교하여 한국어 환경에서의 LLM 탐지 성능 한계를 실증적으로 규명함으로써 비영어권 언어 탐지 연구의 필요성을 강조하였다. 이를 통해 한국어 데이터셋 구축, 허위정보 탐지 프롬프트 설계에 판단 기준 반영, 요약 방식이 탐지 성능에 미치는 영향 분석 등 학문적 기여를 이루었다.

5.2. 실무적 기여

본 연구는 가짜뉴스 탐지가 실무적으로 미칠 수 있는 긍정적 효과를 강조하였다. 개선된 프롬프트를 활용하여 디지털 플랫폼은 뉴스 콘텐츠의 신뢰도를 신속히 평가하고, 가짜뉴스 확산을 효과적으로 억제할 수 있다. 이러한 탐지 기술은 실시간 필터링 시스템으로 구현되어 대중이 접하는 정보의 질을 높이고 미디어 환경의 신뢰성을 강화할 수 있다.

또한, LLM 기반 탐지 기술은 다양한 언어와 맥락을 고려하여 글로벌 수준에서 가짜뉴스 문제에 대응할 수 있는 솔루션을 제공할 수 있다. 특히, 생성형 요약을 활용하여 가짜뉴스의 핵심 특징을 요약함으로써 정보의 신뢰성을 증진시키는 데 기여할 수 있다. 이와 같은 기술은 뉴스 제작 및 배포 과정에서 발생할 수 있는 오류를 줄이고, 대중의 정보 소비 경험을 개선하는 데 긍정적인 영향을 미칠 것이다.

5.3 한계점 및 향후 연구방향

본 연구는 몇 가지 한계를 지니며, 이를 극복하기 위한

향후 연구 방향이 제안된다.

첫째, 연구에 사용된 데이터셋은 전문 기자가 작성한 고품질 기사로 구성되어 있어 감성적이거나 단순한 구조의 콘텐츠에 대한 탐지 성능을 일반화하기 어렵다. 따라서, 다양한 유형의 가짜뉴스를 포함하는 데이터셋을 확장하여 모델의 범용성을 평가하는 연구가 필요하다.

둘째, 영어 중심으로 훈련된 LLM이 한국어 텍스트를 처리할 때 나타나는 언어적 편향을 극복하기 위해 다국어 학습 모델 개발이 요구된다.

셋째, 분류 정확도를 향상시키기 위해 판단 기준을 추가하거나 LLM의 자기 설명 기능을 활용하여 정교한 탐지 프레임워크를 구축해야 한다.

마지막으로, 실제 환경에서 LLM 기반 탐지 시스템이 어떻게 활용될 수 있을지에 대한 심층적 평가와 다양한 실무적 시나리오를 고려한 연구가 필요하다.

5.4. 결론

본 연구는 한국어 환경에서 LLM이 가짜뉴스 탐지에 가지는 잠재력과 한계를 체계적으로 분석하고, 탐지 성능을 향상시키기 위한 실질적 방안을 제시하였다. 분석 결과, 한국어 데이터셋에서의 탐지 성능은 영어 중심의 기존 연구와 비교하여 낮은 수준을 보였으나, 요약 텍스트 활용과 고급 프롬프트 설계를 통해 성능 개선 가능성을 확인하였다. 특히, 7가지 판단 기준을 반영한 프롬프트 설계는 단순한 텍스트 분류를 넘어 정보 신뢰성을 평가하는 체계적인 틀로 활용될 수 있음을 시사하였다.

앞으로의 연구는 다국어 언어 환경에서 탐지 성능을 극대화하고, 정교한 프롬프트 설계와 데이터셋 확장을 통해 LLM 기반 탐지 기술의 한계를 극복하는 방향으로 나아가야 한다. 이를 통해 LLM 기술은 가짜뉴스 탐지뿐 아니라 신뢰성 높은 지식 관리와 정보 검증 도구로서 더욱 중요한 역할을 할 것이다.

〈참고문헌〉

[국내 문헌]

1. 김민정 (2019). 가짜뉴스(fake news)에서 허위조작정보(disinformation)로. **미디어와 인격권**, 5(2), 43-81.
2. 박성수, 이진창 (2019). 효과적인 가짜 뉴스 탐지를 위한 텍스트 분석과 네트워크 임베딩 방법의 비교 연구. **디지털융합연구**, 17(5), 137-143.
3. 박예은, 안현철 (2023). 생성형 AI는 인간 관리자를 대체할 수 있는가? 자동 생성된 관리자 응답이 고객에 미치는 영향. **지식경영연구**, 24(4), 153-176.
4. 유기동 (2024). LLM 사용자의 민감정보 유출 방지를 위한 지식그래프 기반 챗봇. **지식경영연구**, 25(2), 1-18.
5. 이민철, 윤현식 (2020). 머신러닝을 활용한 가짜리뷰 탐지 연구: 사용자 행동 분석을 중심으로. **지식경영연구**, 21(3), 177-195.
6. 정두흠, 박지혜 (2021). 코로나 19 가짜뉴스의 유형분석: 허위조작정보의 조작특징을 중심으로. **지역과 커뮤니케이션**, 25(4), 216-258.

[국외 문헌]

7. Abdulrahman, A., & Baykara, M. (2020, December). Fake news detection using machine learning and deep learning algorithms. In *2020 international conference on advanced science and engineering (ICOASE)* (pp. 18-23). IEEE.
8. Bondielli, A., & Marcelloni, F. (2019). A survey on fake news and rumour detection techniques. *Information Sciences*, 497, 38-55.
9. Bommasani, R., Hudson, D. A., Adeli, E., Altman, R., Arora, S., von Arx, S., ... & Liang, P. (2021). On the opportunities and risks of foundation models. *arXiv preprint arXiv:2108.07258*.
10. Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., ... & Amodei, D. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33, 1877-1901.
11. Buntain, C., & Golbeck, J. (2017). Automatically identifying fake news in popular twitter threads. In *2017 IEEE international conference on smart cloud (smartCloud)*, 208-215.
12. Devlin, J. (2018). Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*.
13. Gelfert, A. (2018). Fake news: A definition. *Informal Logic*, 38(1), 84-117.
14. Gifu, D. (2023). An intelligent system for detecting fake news. *Procedia Computer Science*, 221, 1058-1065.
15. Horne, B., & Adali, S. (2017, May). This just in: Fake news packs a lot in title, uses simpler, repetitive content in text body, more similar to satire than real news. In *Proceedings of the International AAAI Conference on Web and Social Media*, 11(1), 759-766.
16. Hu, B., Sheng, Q., Cao, J., Shi, Y., Li, Y., Wang, D., & Qi, P. (2024, March). Bad actor, good advisor: Exploring the role of large language models in fake news detection. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 38(20), 22105-22113.
17. Huang, Y., Shu, K., Yu, P. S., & Sun, L. (2024, May). From Creation to Clarification: ChatGPT's Journey Through the Fake News Quagmire. In *Companion Proceedings of the ACM on Web Conference 2024*, 513-516.
18. Jiang, B., Tan, Z., Nirmal, A., & Liu, H. (2024). Disinformation detection: An evolving challenge in the age of LLMs. In *Proceedings of the 2024 SIAM International Conference on Data Mining (SDM)* (pp. 427-435). Society for Industrial and Applied Mathematics.
19. Kahneman, D. (2011). *Thinking, fast and slow*. Farrar, Straus and Giroux.
20. Kazemi, A., Li, Z., Pérez-Rosas, V., & Mihalcea, R. (2021). Extractive and abstractive explanations for fact-checking and evaluation of news. *arXiv preprint arXiv:2104.12918*.
21. Kim, A., & Dennis, A. R. (2019). Says who? The effects of presentation format and source rating on fake news in social media. *Mis Quarterly*, 43(3), 1025-1039.
22. Li, X., Zhang, Y., & Malthouse, E. C. (2023). A preliminary study of chatgpt on news recommendation: Personalization, provider fairness, fake news. *arXiv preprint arXiv:2306.10702*.
23. Moravec, P., Minas, R., & Dennis, A. R. (2018). Fake

- news on social media: People believe what they want to believe when it makes no sense at all. *Kelley School of Business Research Paper*, 18–87.
24. Ognyanova, K., Lazer, D., Robertson, R. E., & Wilson, C. (2020). Misinformation in action: Fake news exposure is linked to lower trust in media, higher trust in government when your side is in power. *Harvard Kennedy School Misinformation Review*, 1(4). DOI: 10.37016/mr-2020-024.
 25. OpenAI (2023). Gpt-4 technical report. ArXiv, abs/2303.08774
 26. Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C., Mishkin, P., ... & Lowe, R. (2022). Training language models to follow instructions with human feedback. *Advances in Neural Information Processing Systems*, 35, 27730–27744.
 27. Pan, J. Z., Pavlova, S., Li, C., Li, N., Li, Y., & Liu, J. (2018). Content based fake news detection using knowledge graphs. In *The Semantic Web-ISWC 2018: 17th International Semantic Web Conference*, Monterey, CA, USA, October 8-12, 2018, Proceedings, Part I 17, 669–683.
 28. Papageorgiou, E., Chronis, C., Varlamis, I., & Himeur, Y. (2024). A survey on the use of Large Language Models (LLMs) in fake news. *Future Internet*, 16(8), 298.
 29. Pérez-Rosas, V., Kleinberg, B., Lefevre, A., & Mihalcea, R. (2017). Automatic detection of fake news. *arXiv preprint arXiv:1708.07104*.
 30. Quelle, D., & Bovet, A. (2024). The perils and promises of fact-checking with large language models. *Frontiers in Artificial Intelligence*, 7, 1341697.
 31. Raza, S., & Ding, C. (2022). Fake news detection based on news content and social contexts: A transformer-based approach. *International Journal of Data Science and Analytics*, 13(4), 335–362.
 32. Rossini, P., Mont'Alverne, C., & Kalogeropoulos, A. (2023). Explaining beliefs in electoral misinformation in the 2022 Brazilian election: The role of ideology, political trust, social media, and messaging apps. *Harvard Kennedy School Misinformation Review*, 4(3), 1–16.
 33. Sheikhi, S. (2021). An effective fake news detection method using WOA-xgbTree algorithm and content-based features. *Applied Soft Computing*, 109, 107559.
 34. Shim, J. S., Lee, Y., & Ahn, H. (2021). A link2vec-based fake news detection model using web search results. *Expert Systems with Applications*, 184, 115491.
 35. Touvron, H., Martin, L., Stone, K., Albert, P., Almahairi, A., Babaei, Y., ... & Scialom, T. (2023). Llama 2: Open foundation and fine-tuned chat models. *arXiv preprint arXiv:2307.09288*.
 36. Wu, L., Morstatter, F., Carley, K. M., & Liu, H. (2019). Misinformation in social media: Definition, manipulation, and detection. *ACM SIGKDD Explorations Newsletter*, 21(2), 80–90.
 37. Wynne, H. E., & Wint, Z. Z. (2019, December). Content based fake news detection using n-gram models. In *Proceedings of the 21st International Conference on Information Integration and Web-based Applications & Services*, 669–673.
 38. Xie, A., Zhu, F., Han, J., & Hu, S. (2024, May). Integrating open-domain knowledge via large language model for multimodal fake news detection. In *2024 27th International Conference on Computer Supported Cooperative Work in Design (CSCWD)*, 1917–1922.
 39. Zhang, Q., Shi, S., Zhang, K., Lu, Z., Zhang, T., & Xie, X. (2023, September). Data augmentation for fake news using ChatGPT. In *2023 International Conference on Intelligent Management and Software Engineering (IMSE)*, 12–17.
 40. Zhou, X., Zafarani, R., Shu, K., & Liu, H. (2019, January). Fake news: Fundamental theories, detection strategies and challenges. In *Proceedings of the twelfth ACM international conference on web search and data mining*, 836–837.

[URL]

41. University of Southern California (2024, November 29). Trust in voting: How misinformation threatens democracy. *USC News*, <https://today.usc.edu/trust-in-voting-how-misinformation-threatens-democracy/>

● 저 자 소 개 ●



고 상 훈 (Sanghun Ko)

현재 국민대학교 비즈니스IT전문대학원 석사과정에 재학 중이며, 중앙대학교에서 심리학 전공 학사 학위를 취득하였다. 주요 연구 분야는 비즈니스 애널리틱스(BA), 빅데이터 분석, 인공지능(AI) 등이다.



안 현 철 (Hyunchul Ahn)

현재 국민대학교 비즈니스IT전문대학원 교수로 재직 중이다. KAIST에서 산업경영학사를 취득하고, KAIST 테크노경영대학원에서 경영정보시스템을 전공하여 공학석사와 박사를 취득하였다. 주요 관심분야는 정보시스템 수용과 관련한 행동 모형, 금융 및 고객관계관리 분야의 인공지능 응용 등이다. 지금까지 Applied Soft Computing, Applied Intelligence, Expert Systems with Applications, Information & Management, International Journal of Electronic Commerce, International Journal of Information Management 등 주요 학술지에 논문을 발표하였다.

〈 Abstract 〉

Detecting Fake News in Korean Using Large Language Models: Limitations and Possibilities

Sang Hun Ko*, Hyunchul Ahn**

Fake news spreads rapidly through digital platforms and social media and has become an important problem that negatively impacts social trust and public discourse. Recent advances in Large Language Models (LLMs) have opened up new possibilities for natural language processing techniques, and their use is also contributing to solving important social problems such as fake news detection. This study aims to analyze the possibilities and limitations of LLM-based fake news detection in the Korean environment, focusing on misinformation among the different types of fake news. To this end, we constructed a benchmark dataset based on 500 Korean news articles collected from SNU FactCheck. Further, we designed extracted and generated datasets by applying the article summarization method. This study centered on three research questions: (1) is LLM-based fake news detection effective in the Korean environment? (2) which summarization method is effective in detecting fake news using LLM, and (3) what is the optimal way to improve detection performance? The results showed that LLM-based detection accuracy in the Korean dataset was lower (59.8%) compared to English-focused studies. In addition, detection performance in experiments using summarized text decreased as sentences became shorter, and generated summaries performed slightly better than extracted summaries. Finally, we improved the detection accuracy slightly (62.1%) by introducing an improved prompt that reflects the seven reasons for fake news detection. This study extends the LLM-based fake news detection research in the Korean environment. It demonstrates that an advanced prompt design and an approach considering contextual factors can improve detection performance. The findings suggest the feasibility of utilizing LLM not only for fake news detection but also in various linguistic and cultural contexts, which have important implications for future research and practical applications.

Key words: Fake news detection, Misinformation, Large Language Model, Korean dataset, Summarization

* Graduate School of Business IT, Kookmin University

** Graduate School of Business IT, Kookmin University

